Dataset proiecte de research UE și impactul lor

Oct 23, 2026 · @Delia

Context

Proiectul construiește un dataset cu proiecte de research finanțate de UE și impactul lor. Proiectele vin din CORDIS, iar citările din OpenAlex, legate prin DOI. Profesorul a ridicat trei probleme: acoperirea datelor, definiția impactului și momentul în care apar articolele.

- **Acoperirea datelor:** nu e sigur că CORDIS conține tot ce trebuie; el recomandă Zenodo și o perioadă fixă, de exemplu 5 ani.
- **Impactul:** nu e bine definit; un survey foarte citat nu înseamnă impact real.
- **Momentul articolelor:** proiectele raportează publicațiile la început sau la final, iar concluziile se adaugă la sfârșit.

1. Sursele de date

Pornim de la proiect, nu de la articol, și legăm outputurile de proiect prin ID-ul grantului, nu doar prin DOI. Câmpurile exacte ale API-urilor nu au fost verificate încă, deci trebuie confirmate înainte de pipeline.

Sursă	Ce aduce
CORDIS	Metadatele proiectelor: titlu, obiectiv, buget, date, coordonator, consorțiu, domeniu. Are și descărcări în masă pe data.europa.eu.
OpenAIRE Graph	Leagă proiectele de publicații, dataseturi și software pe baza grant ID-ului. Prinde și lucrările apărute după finalul proiectului, pe care CORDIS le poate rata. Include conținut din Zenodo.
OpenAlex	Citări, tipul lucrării, domeniul, FWCI (citări normalizate pe domeniu și an) și percentila de citare.

Sursă	Ce aduce
Zenodo	Dataseturi și software cu grant UE în metadate. Permite măsurarea vizualizărilor, descărcărilor și citărilor.

2. Perioada

Propunere: proiecte H2020 încheiate între 2018 și 2022, de exemplu. Horizon Europe e prea recent, pentru că citările nu au avut timp să se acumuleze.

Fixăm și o fereastră de observare, de exemplu citări la 3 ani după finalul proiectului, ca proiectele să fie comparabile între ele.

3. Definiția impactului

Citările brute păcălesc: un survey foarte citat nu înseamnă impact real. Propunem mai multe metrici, nu una singură.

Dimensiune	Metrici
Științific	FWCI mediu pe proiect, % de articole în top 10%, citări fără autocitări
Output deschis	Nr. de dataseturi/software pe Zenodo, descărcări, citări ale lor
Colaborare	Nr. de țări și organizații, interdisciplinaritate
Eficiență	Citări sau articole la 1 milion € finanțat
Acces	% de articole open access

Survey-urile se marchează cu un flag (OpenAlex are tipul „review”), iar metricile se calculează și cu, și fără ele. Așa se poate arăta în raport că problema a fost tratată.

4. Problema „articolul apare la început”

Proiectele raportează publicațiile la început sau la final, iar concluziile se adaugă târziu, deci raportul din CORDIS nu e complet. Soluții:

- Luăm outputurile din OpenAIRE și OpenAlex după grant ID, nu doar din raportul din CORDIS.
- Păstrăm data publicării fiecărui output față de data de start și de final a proiectului, ca să separăm „publicat în timpul proiectului” de „publicat după”.
- Pentru unele proiecte, CORDIS are și rezumatul rezultatelor finale. E text util pentru concluzii și poate deveni o coloană în plus.

5. Structura datasetului

Patru tabele, legate între ele prin ID-ul proiectului.

Tabel	Conținut
projects	id, titlu, obiectiv, program, domeniu, buget, date start/end, țara coordonatorului
organisations	proiect, organizație, țară, tip, rol
outputs	proiect, DOI, tip (articol, review, dataset, software), an, citări, FWCI, open access
project_metrics	metricile agregate pe proiect, din secțiunea 3

6. Ce se poate face cu el

- Predicția impactului unui proiect din text, buget și consorțiu
- Analiza textului obiectivelor (topic modeling, clustering)
- Rețele de colaborare între țări și instituții
- Comparații pe domenii și pe mărimea consorțiului

7. Întrebări pentru echipă și pasul următor

Înainte de a fixa definiția, echipa trebuie să răspundă la patru întrebări:

- [ ] Unitatea de analiză e proiectul sau publicația?
- [ ] Toate domeniile sau doar câteva, ca să fie mai gestionabil?
- [ ] Care e scopul final: doar dataset, sau și o analiză ori un model?
- [ ] Câte proiecte ne propunem: sute sau mii?

Pasul următor propus: un pilot pe 20-50 proiecte reale, interogând API-urile OpenAIRE și OpenAlex, ca să se vadă cât de complete sunt datele înainte de a bloca o definiție.